



Universidade de São Paulo - São Carlos

Instituto de Ciências Matemáticas e de Computação

Trabalho Prático T1 – Exercícios sobre a DML

Docente: Caetano Traina Jr. — caetano@icmc.usp.br

PAE: Gabriel Lucca de Melo — melogabriel@usp.br 1º Semestre de 2026

Data para entrega: 15 de abril de 2026

Datasets

Base de dados da Fórmula 1 - FIA, com as cidades e aeroportos do mundo.

A base de dados a ser utilizada é a mesma preparada no **Projeto Prático 3**. Caso necessário, os arquivos originais para a carga de dados encontram-se no Google Drive, e podem ser acessados no endereço [este link](#). Para acessar os arquivos, você deve estar logado no Google Drive com sua conta USP. Cada arquivo corresponde a uma tabela, que deve ser carregada na base de dados.

Os dados originais foram ligeiramente modificados para facilitar o trabalho. Mas você pode usar os dados originais se quiser, por exemplo, para incluir os dados atualizados das últimas corridas. Nesse caso, eles podem ser obtidos nos seguintes *sites*:

- Dados da Fórmula-1: [Formula 1 Championships \(1950-2025\) – Kaggle](#)
 - Países e Cidades do planeta: [GeoNames](#)
 - Aeroportos: [OurAirports](#)
-

Atividades da semana

A atividade da semana é composta de duas partes usando o SGBD escolhido:

1. efetuar uma limpeza preliminar para melhorar a qualidade dos dados carregados; e
2. executar consultas sobre eles.

Melhorar a qualidade dos dados

Visando melhorar o esquema e a qualidade dos dados, aproximando as atividades da disciplina de cenários reais, deverá ser realizada uma etapa adicional de limpeza, normalização e tratamento de inconsistências sobre o modelo relacional e os dados utilizados no projeto.

Esta é uma etapa importante que inclui a reflexão sobre a modelagem e integridade de dados, que deve sempre ser considerada pelo profissional responsável em suas atividades. Neste trabalho, deverão ser executadas as seguintes atividades:

- Alterar o esquema relacional para melhorar a qualidade dos dados e do desempenho das consultas subsequentes:
 - substituir o atributo textual de nacionalidade nas entidades [Pilotos](#) e [Construtores](#) por uma referência à entidade [Países](#);
 - incluir o atributo [Nacionalidade](#) na entidade [Países](#);
- Durante o processo de migração dos dados, as inconsistências identificadas deverão ser tratadas adequadamente, de modo a atender ao esquema relacional definido e aos requisitos de qualidade dos dados;
- Execução de uma etapa de deduplicação da entidade [Cidades](#), considerando que esse é um caso com alta variabilidade nos dados provenientes de diferentes fontes.

Para a deduplicação, deverão ser realizadas as seguintes atividades:

- identificar registros que se referem à mesma cidade, considerando atributos como nome, país e/ou proximidade geográfica;
- definir critérios de equivalência entre registros;
- consolidar registros duplicados, mantendo o mais completo ou realizando a integração ([merge](#)) das informações;
- atualizar as referências nas demais tabelas (como [Aeroportos](#) e [Circuitos](#)), garantindo que não haja perda dos vínculos;
- apresentar métricas do processo, incluindo quantidade de registros antes e depois, número de duplicatas tratadas, dentre os indicadores relevantes.

Um problema prático recorrente nos processos de integração de dados provenientes de fontes diferentes é a ocorrência de variações na representação textual dos valores. No contexto deste trabalho, esse problema ocorre principalmente nos nomes de cidades oriundos das três diferentes bases originais que usamos (Fórmula 1, GeoNames e Aeroportos). A correção dessas inconsistências é conhecida como deduplicação de dados.

Em alguns casos, é possível aplicar regras de transformação textual (por exemplo, utilizando expressões regulares) para padronização dos dados. No entanto, isso nem sempre é suficiente, sendo necessário definir critérios mais robustos de equivalência.

Dicas:

- Para definir critérios de equivalência entre cidades provenientes de fontes distintas, pode-se considerar que não existem cidades diferentes a menos de 1,0 km de distância;
- Nem todas as inconsistências poderão ser tratadas automaticamente, sendo necessário estabelecer regras claras e justificadas;
- Atenção para garantir que as alterações realizadas não comprometam a integridade referencial do banco de dados.

Executar consultas sobre os dados

O objetivo desta parte é reconhecer a estrutura das tabelas da base, para executar consultas interessantes para obter informações para a Fórmula Um.

Exercício 1) Liste o total de pontos obtido por cada piloto, por ano e em ordem decrescente de pontuação.

Dica: Os pontos obtidos em cada corrida estão na tabela [DriverStandings](#).

Exercício 2) Selecione o nome do piloto que partiu mais vezes em primeiro lugar (*grid*) da história. Apresente o nome completo do piloto e a quantidade de vezes.

Dica: Considere a tabela [RESULTS](#).

Exercício 3) Para cada país que sedia corridas, liste a quantidade de cidades e o número total de aeroportos existentes nesse país.

Dica: Inicialmente, filtre os países que possuem vínculo com os circuitos e, posteriormente, realize a contagem.

Entrega da semana

Cada equipe deverá entregar dois arquivos:

1. Um arquivo no formato `.sql` contendo:
 - as alterações no esquema relacional;
 - os scripts de transformação e limpeza dos dados;
 - as atualizações necessárias para garantir consistência e integridade;
 - os comandos de execução das consultas.
2. Um arquivo no formato `.pdf` contendo um relatório sucinto com:
 - a descrição das alterações realizadas no modelo;
 - os critérios adotados para identificação de duplicatas;
 - as estratégias utilizadas para deduplicação;
 - as métricas obtidas pela execução do processo de correção (quantidade de registros antes/depois, duplicatas tratadas, etc.);
 - exemplos dos testes de cada consulta (por exemplo, uma captura de tela do resultado. Para resultados muito longos, mostrar somente as primeiras 10 primeiras linhas do resultado.
 - descrição das principais dificuldades encontradas e as decisões tomadas.

O relatório deve evidenciar claramente as decisões adotadas pelo grupo e justificar as escolhas realizadas no processo de limpeza e normalização dos dados.

Como a atividade tem prazo de entrega máximo de uma hora antes da próxima aula, os arquivos devem ser submetidos

até às **18:00 do dia 15 de abril de 2026**
com a **postagem apenas do líder da equipe.**

Bom Trabalho!